Introduction à la bioinformatique (UE SSV3U15)
TP4. Alignement par paire et alignement multiple

Jacques van Helden, Emese Meglécz, Yvan Perez et Andreas Zanzoni

Objectifs et notions

Objectifs

- L'objectif de ce TP est de découvrir les sites web permettant de générer des alignements par paire ou alignements multiples de séquences protéiques et d'essayer d'y localiser les domaines et de modéliser la famille pour en détecter tous les membres.

Notions mises en pratique

- **Recherche par similarité** : alignement par paire d'une séquence d'intérêt (requête, "query") avec toutes les séquences d'une base de données ("subject")
  - Alignement local
  - Eléments de l'alignement : matches, mismatches, indels
- **Alignements multiples**
  - identifier les blocs de conservation, les régions plus variables, les domaines fonctionnels
  - distinguer les insertions des délétions, ce qui n'était pas possible sur base d'un alignement par paire
  - constater la présence de substitutions plus fréquentes que d'autres
- **Matrices de substitution**
  - Liens avec la biochimie

N'oubliez pas que vous pouvez à tout moment consulter le **glossaire du cours** pour obtenir une définition sommaire des principaux termes utilisés.

Déroulé du TP

Etapes

- Exercice 1. ***Alignement par paire et alignement multiple au NCBI***
  - Observation et compréhension des résultats de BLAST
  - Téléchargement d'un ensemble de séquences homologues
- Exercice 2. ***Alignement multiple à l'EBI***
  - Alignement multiple
  - Outil de visualisation et d'édition d'un alignement multiple (Jalview)

Bacteriorhodopsin

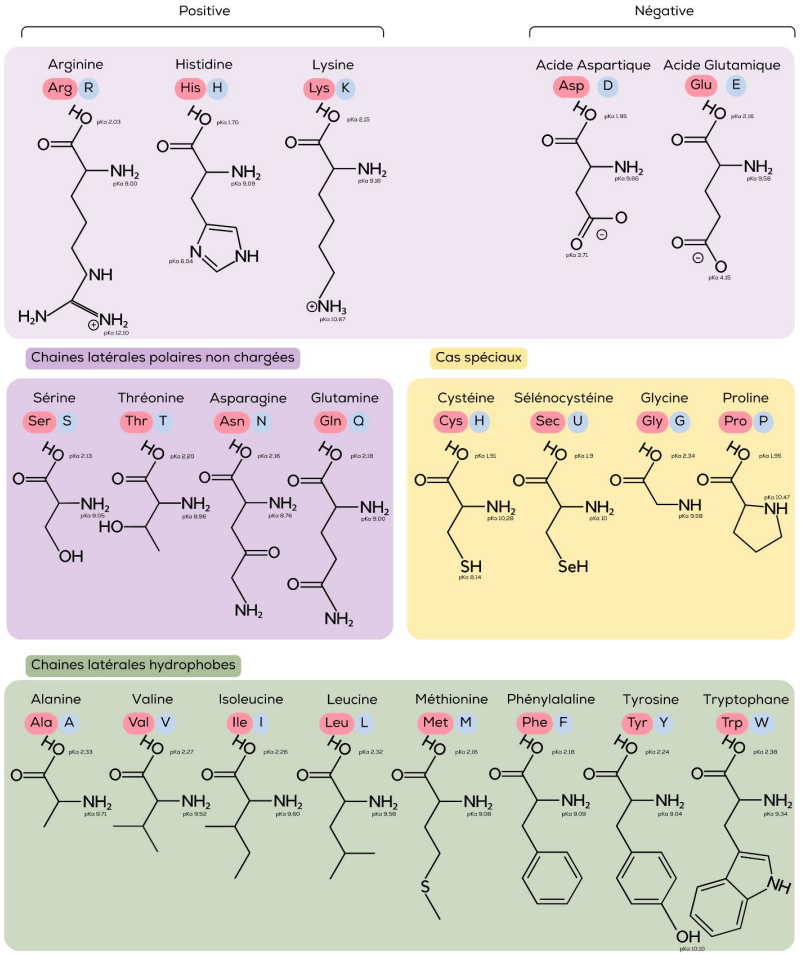
Les **bactériorhodopsines** sont des **protéines membranaires** présentes chez certaines **archées** halophiles extrêmes (et non chez les bactéries, contrairement à ce que leur nom suggère). Elles permettent de **convertir l'énergie lumineuse en énergie chimique** en pompant des protons à travers la membrane, contribuant ainsi à la synthèse d'ATP.

Ces protéines appartiennent à une famille plus large de **rhodopsines**, qui utilisent toutes un chromophore pour capter la lumière. Chez les archées, ce processus sert à la production d'énergie, tandis que chez les animaux, des protéines apparentées — les opsines visuelles — utilisent le même principe pour détecter la lumière et initier la perception visuelle.

Rappel des définitions

Rappel – Nomenclature et composition des acides aminés

Amino Acid	Abbrev	1-lettre	Codon(s)
Alanine	Ala	A	GCA, GCC, GCG, GCT
Arginine	Arg	R	CGA, CGC, CGG, CGT, AGA, AGG
Aspartic acid	Asp	D	GAC, GAT
Asparagine	Asn	N	AAC, AAT
Cysteine	Cys	C	TGC, TGT
Glutamic acid	Glu	E	GAA, GAG
Glutamine	Gln	Q	CAA, CAG
Glycine	Gly	G	GGA, GGC, GGG, GGT
Histidine	His	H	CAC, CAT
Isoleucine	Ile	I	ATA, ATC, ATT
Leucine	Leu	L	CTA, CTC, CTG, CTT, TTA, TTG
Lysine	Lys	K	AAA, AAG
Methionine	Met	M	ATG
Phenylalanine	Phe	F	TTC, TTT
Proline	Pro	P	CCA, CCC, CCG, CCT
Serine	Ser	S	TCA, TCC, TCG, TCT, AGC, AGT
Threonine	Thr	T	ACT, ACC, ACG, ACT
Tryptophan	Trp	W	TGG
Tyrosine	Tyr	Y	TAC, TAT
Valine	Val	V	GTA, GTC, GTG, GTT
STOP	-	-	TAG, TAA, TGA



https://upload.wikimedia.org/wikipedia/commons/9/91/Les_21_acides_amin%C3%A9s.png

Matrice de substitutions

- Une ***matrice de substitution*** associe un score à chaque paire de résidus qu'on peut trouver dans un alignement.
  - Chaque ligne et chaque colonne représente l'un des résidus (4 nucléotides, 20 acide aminés).
  - La diagonale correspond aux identités.
  - Le triangle inférieur correspond à des substitutions.
  - Le triangle supérieur est symétrique au triangle inférieur, il n'est pas nécessaire d'indiquer les nombres.
- Les ***scores négatifs*** sont considérés comme des pénalités associées à certaines substitutions qu'on n'observe que rarement dans les alignements. Les algorithmes d'alignements tenteront donc d'éviter ces substitutions.
- Les ***scores positifs*** correspondent à des substitutions qu'on observe plus souvent que prévu, dans les alignements d'un grand nombre de séquences. Ceci suggère que ces substitutions particulières sont moins dommageable que d'autres, et on les qualifie donc de « ***substitutions conservatives*** » ou encore de « ***mutations ponctuelles acceptées*** » (***PAM***).

Matrice de substitutions entre nucléotides

	A	C	G	T
A	1	-2	-1	-2
C	-2	1	-2	-1
G	-1	-2	1	-2
T	-2	-1	-2	1

Scores	
1	identité
-1	transition
-2	transversion

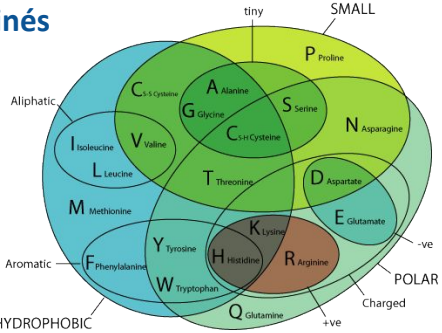
Matrice de substitutions entre acides aminés

Ala	A	4																		
Arg	R	-1	5																	
Asn	N	-2	0	6																
Asp	D	-2	-2	1	6															
Cys	C	0	-3	-3	-3	9														
Gln	Q	-1	1	0	0	-3	5													
Glu	E	-1	0	0	2	-4	2	5												
Gly	G	0	-2	0	-1	-3	-2	-2	6											
His	H	-2	0	1	-1	-3	0	0	-2	8										
Ile	I	-1	-3	-3	-3	-1	-3	-3	-4	-3	4									
Leu	L	-1	-2	-3	-4	-1	-2	-3	-4	-3	2	4								
Lys	K	-1	2	0	-1	-3	1	1	-2	-1	-3	-2	5							
Met	M	-1	-1	-2	-3	-1	0	-2	-3	-2	1	2	-1	5						
Phe	F	-2	-3	-3	-3	-2	-3	-3	-3	-1	0	0	-3	0	6					
Pro	P	-1	-2	-2	-1	-3	-1	-1	-2	-2	-3	-3	-1	-2	-4	7				
Ser	S	1	-1	1	0	-1	0	0	0	-1	-2	-2	0	-1	-2	-1	4			
Thr	T	0	-1	0	-1	-1	-1	-1	-2	-2	-1	-1	-1	-1	-2	-1	1	5		
Trp	W	-3	-3	-4	-4	-2	-2	-3	-2	-2	-3	-2	-3	-1	1	-4	-3	-2	11	
Tyr	Y	-2	-2	-2	-3	-2	-1	-2	-3	2	-1	-1	-2	-1	3	-3	-2	-2	2	7
Val	V	0	-3	-3	-3	-1	-2	-2	-3	-3	3	1	-2	1	-1	-2	-2	0	-3	-1	4
		Ala	Arg	Asn	Asp	Cys	Gln	Glu	Gly	His	Ile	Leu	Lys	Met	Phe	Pro	Ser	Thr	Trp	Tyr	Val
		A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V

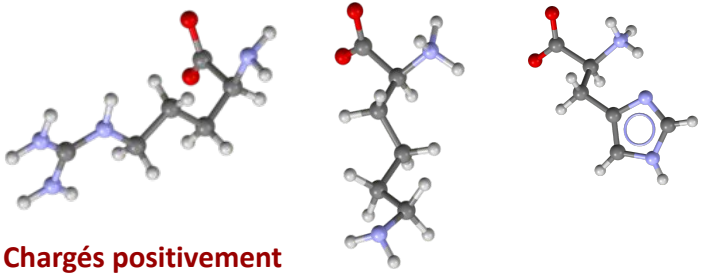
Similarités chimiques entre acides aminés et matrices de substitution

Matrice de substitutions entre acides aminés

		A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V
Ala	A	4																			
Arg	R	-1	5																		
Asn	N	-2	0	6																	
Asp	D	-2	-2	1	6																
Cys	C	0	-3	-3	-3	9															
Gln	Q	-1	1	0	0	-3	5														
Glu	E	-1	0	0	2	-4	2	5													
Gly	G	0	-2	0	-1	-3	-2	-2	6												
His	H	-2	0	1	-1	-3	0	0	-2	8											
Ile	I	-1	-3	-3	-3	-1	-3	-3	-4	-3	4										
Leu	L	-1	-2	-3	-4	-1	-2	-3	-4	-3	2	4									
Lys	K	-1	2	0	-1	-3	1	1	-2	-1	-3	-2	5								
Met	M	-1	-1	-2	-3	-1	0	-2	-3	-2	1	2	-1	5							
Phe	F	-2	-3	-3	-3	-2	-3	-3	-3	-1	0	0	-3	0	6						
Pro	P	-1	-2	-2	-1	-3	-1	-1	-2	-2	-3	-3	-1	-2	-4	7					
Ser	S	1	-1	1	0	-1	0	0	0	-1	-2	-2	0	-1	-2	-1	4				
Thr	T	0	-1	0	-1	-1	-1	-1	-2	-2	-1	-1	-1	-1	-2	-1	1	5			
Trp	W	-3	-3	-4	-4	-2	-2	-3	-2	-2	-3	-2	-3	-1	1	-4	-3	-2	11		
Tyr	Y	-2	-2	-2	-3	-2	-1	-2	-3	2	-1	-1	-2	-1	3	-3	-2	-2	2	7	
Val	V	0	-3	-3	-3	-1	-2	-2	-3	-3	3	1	-2	1	-1	-2	-2	0	-3	-1	4
		Ala	Arg	Asn	Asp	Cys	Gln	Glu	Gly	His	Ile	Leu	Lys	Met	Phe	Pro	Ser	Thr	Trp	Tyr	Val
		A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V

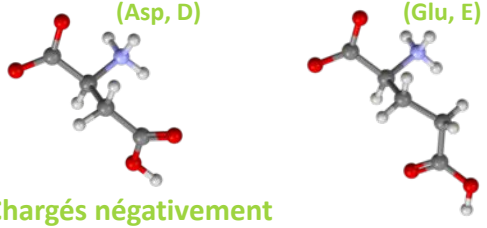


Lysine (Lys, K) **Arginine (Arg, R)** **Histidine (His, H)**



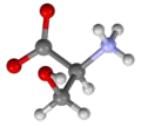
Chargés positivement

Acide aspartique (Asp, D) **Acide glutamique (Glu, E)**



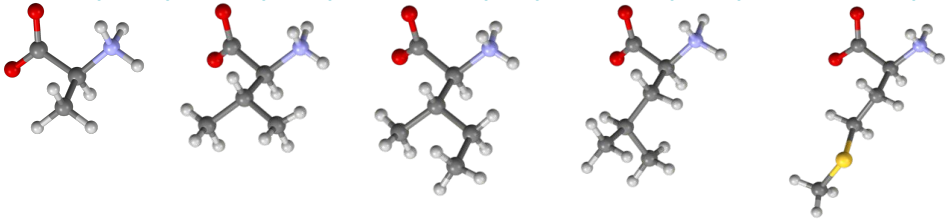
Chargés négativement

Sérine (Ser, S)



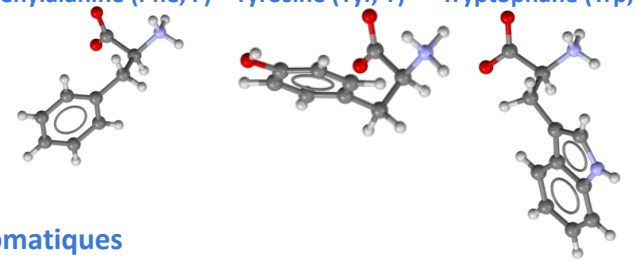
Polaires non chargés

Alanine (Ala, A) **Valine (Val, V)** **Isoleucine (Ile, I)** **Leucine (Leu, L)** **Méthionine (Met, M)**



Hydrophobes

Phénylalanine (Phe, F) **Tyrosine (Tyr, Y)** **Tryptophane (Trp, W)**



Aromatiques

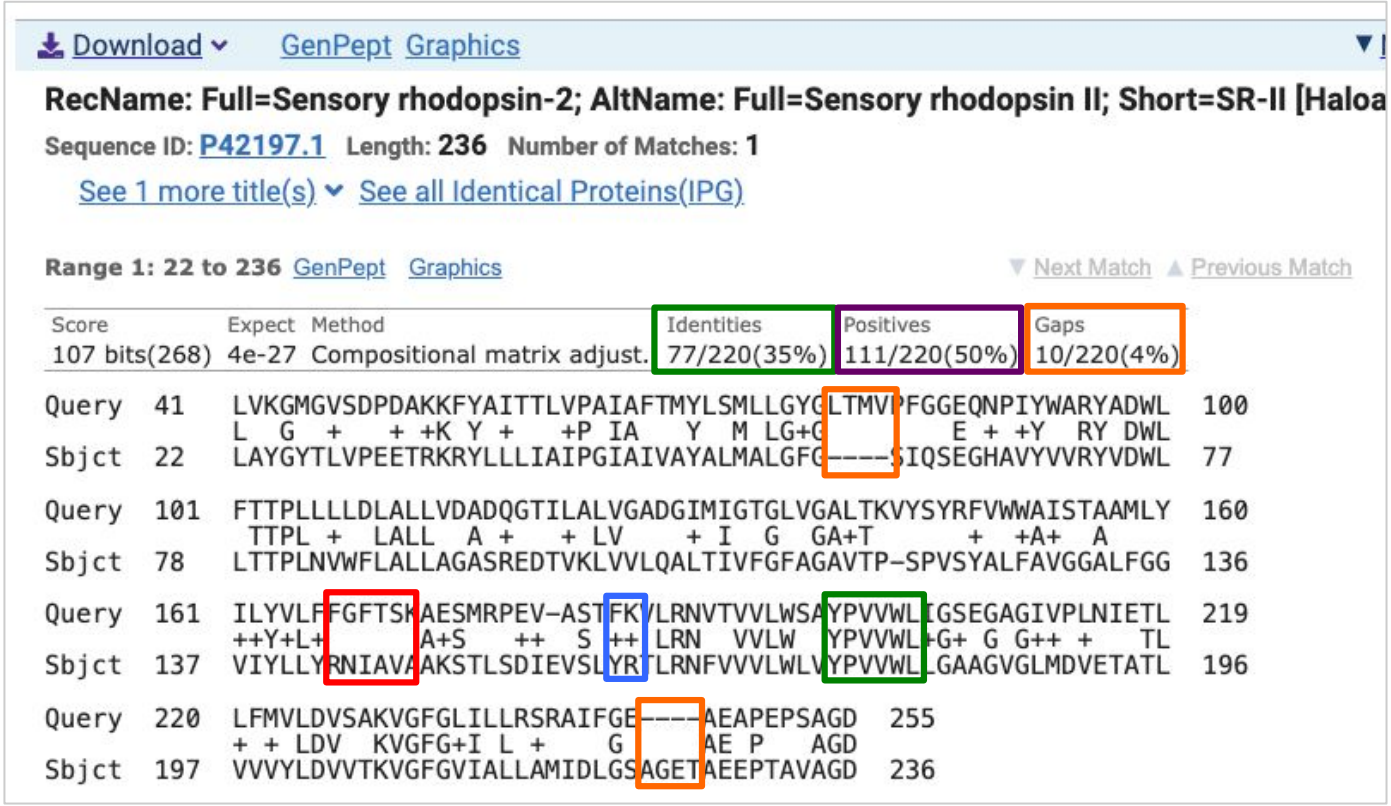
Matrice de substitutions

En cas de difficulté, vous pouvez consulter sur AMUpod la vidéo-tuto sur les alignements et les matrices de scores (abordée lors du TP2), en particulier la section de 3:54 à 6:20, qui traite des matrices de substitution des acides aminés.

Exemple d'alignement par paire

- La ligne entre les séquences "Query" et "Sbjct" indique les correspondances entre acides aminés.
- Identités
- Substitutions "conservatives": paires de résidus distincts mais dont la substitution est généralement moins délétère que pour d'autres paires de résidus.
- Substitutions non conservatives
- Positives: identités + substitutions conservatives.
- Gaps: lacunes insérées dans une séquence afin d'optimiser l'alignement des fragments avoisinants.

Note: le mode de représentation des identités, substitutions conservatives et gaps varie d'un outil à l'autre.



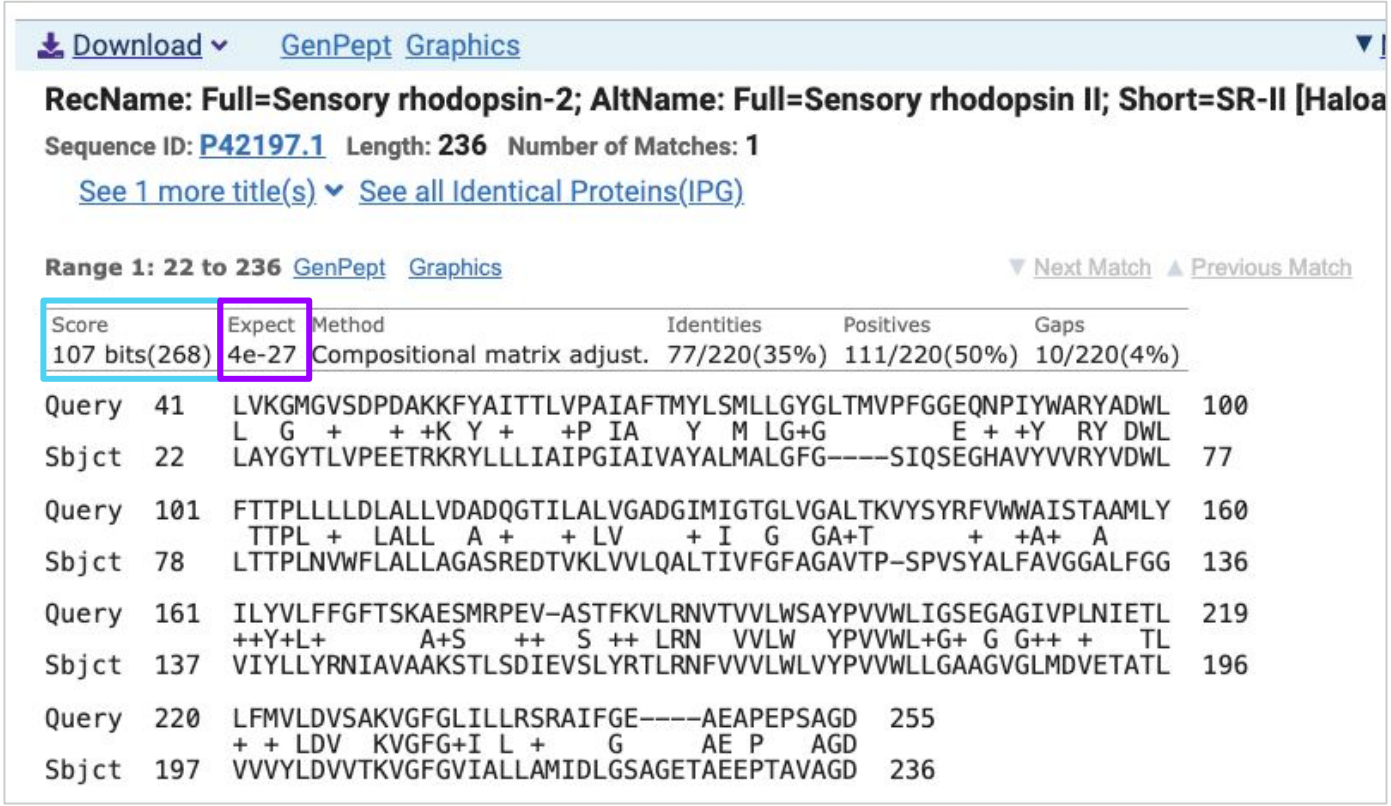
Résultat de BLAST – Scores d'alignement

Exemple de résultat de recherche par similarité de séquences.

- Requête (**query**): metA
- Protéine identifiée dans la base de données: (**subject**): thrA.

Le premier critère d'évaluation d'un résultat de BLAST:

- La **e-valeur (expect)** indique le nombre de faux-positifs attendus au hasard, si l'on plaçait le seuil au niveau du score observé (score brut de **268** dans ce cas-ci).
- **Plus la e-valeur est faible, plus le résultat est statistiquement significatif.** Dans le cas présent, il est très significatif (**Expect = 4e-27**)
- **Si la e-valeur est ≥ 1, le résultat n'est pas significatif** (on s'attendrait à trouver un alignement « aussi bon » avec des séquences aléatoires.



Download GenPept Graphics

RecName: Full=Sensory rhodopsin-2; AltName: Full=Sensory rhodopsin II; Short=SR-II [Haloa

Sequence ID: P42197.1 Length: 236 Number of Matches: 1

See 1 more title(s) See all Identical Proteins(IPG)

Range 1: 22 to 236 GenPept Graphics Next Match Previous Match

Score	Expect	Method	Identities	Positives	Gaps
107 bits(268)	4e-27	Compositional matrix adjust.	77/220(35%)	111/220(50%)	10/220(4%)

```
Query  41   LVKGMGVSDPDAKKFYAITTLVPAIAFTMYLSMLLGYGLTMVPFGGEQNPIYWARYADWL  100
            L  G  +   + +K Y +   +P IA   Y  M LG+G         E + +Y  RY DWL
Sbjct  22   LAYGYTLVPEETRKRYLLLIAIPGIAIVAYALMALGFG----SIQSEGHAVYVVRYVDWL  77

Query  101  FTTPLLLLDLALLVDADQGTILALVGADGIMIGTGLVGALTKVYSYRFVWWAISTAAMLY  160
             TTPL +  LALL  A +   + LV    + I  G  GA+T       +  +A+  A
Sbjct  78   LTTPLNVWFLALLAGASREDTVKLVVLQALTIVFGFAGAVTP-SPVSYALFAVGGALFGG  136

Query  161  ILYVLFFGFTSKAESMRPEV-ASTFKVLRNVTVVLWSAYPVVWLIGSEGAGIVPLNIETL  219
            ++Y+L+      A+S   ++  S ++ LRN  VVLW  YPVVWL+G+ G G++ +   TL
Sbjct  137  VIYLLYRNIAVAAKSTLSDIEVSLYRTLRNFVVVLWLVYPVVWLLGAAGVGLMDVETATL  196

Query  220  LFMVLDVSAKVGFGLILLRSRAIFGE----AEAPEPSAGD  255
            + + LDV  KVGFG+I L +    G     AE P   AGD
Sbjct  197  VVVYLDVVTKVGFGVIALLAMIDLGSAGETAEEPTAVAGD  236
```

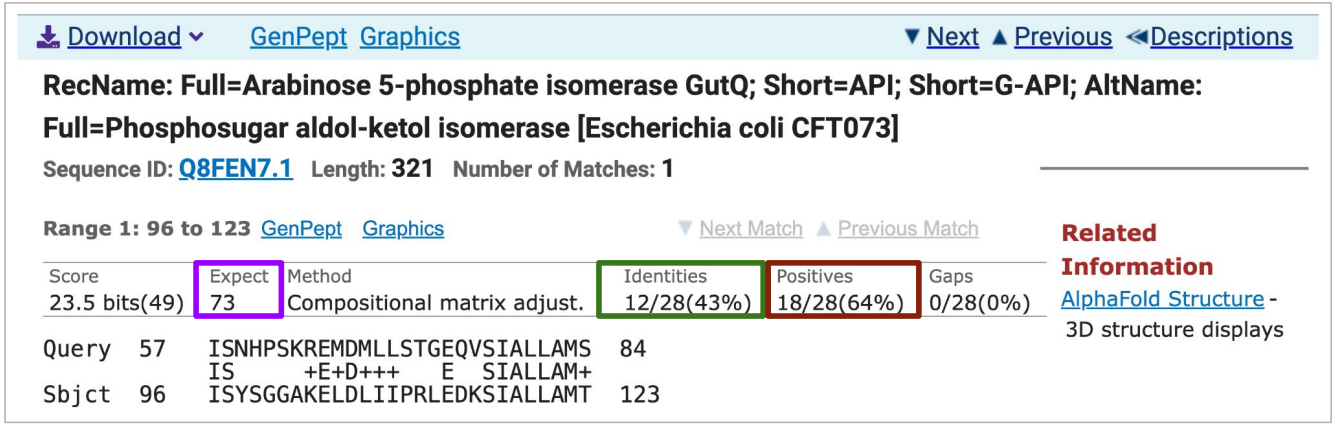
Le piège des alignements non-significatifs

Captures d'écran de BLAST

- Haut: alignement entre la protéine P53553 de *Geobacillus* et une protéine de *Escherichia coli*.
- Bas: alignement entre une séquence aléatoire et une protéine d'*Escherichia coli*.

Les deux alignements présentent des taux élevés **d'identité** et de **similarité** (valeurs **positives** dans la matrice de substitution), mais la **E-valeur** indique sans ambiguïté qu'ils ne sont **absolument pas significatifs**.

Les correspondances sont fortuites, et leur pourcentage élevé s'explique par les petites tailles des alignements.



Download GenPept Graphics ▼Next ▲Previous ◀◀Descriptions

RecName: Full=Arabinose 5-phosphate isomerase GutQ; Short=API; Short=G-API; AltName: Full=Phosphosugar aldol-ketol isomerase [Escherichia coli CFT073]

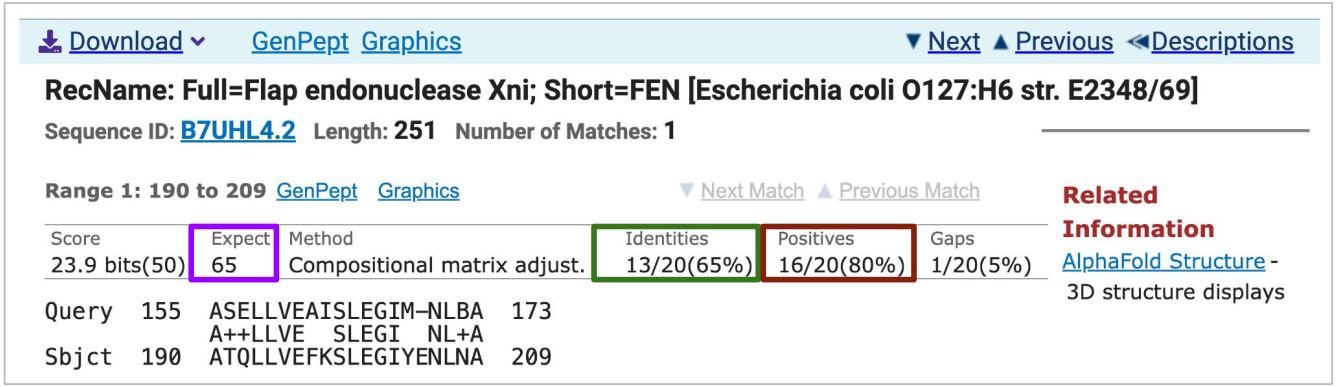
Sequence ID: Q8FEN7.1 Length: 321 Number of Matches: 1

Range 1: 96 to 123 GenPept Graphics ▼Next Match ▲Previous Match

Score	Expect	Method	Identities	Positives	Gaps
23.5 bits(49)	73	Compositional matrix adjust.	12/28(43%)	18/28(64%)	0/28(0%)

```
Query  57   ISNHPSKREMDMLLSTGEQVSIALLAMS  84
            IS     +E+D+++    E  SIALLAM+
Sbjct  96   ISYSGGAKELDLIIPRLEDKSIALLAMT  123
```

Related Information
AlphaFold Structure - 3D structure displays



Download GenPept Graphics ▼Next ▲Previous ◀◀Descriptions

RecName: Full=Flap endonuclease Xni; Short=FEN [Escherichia coli O127:H6 str. E2348/69]

Sequence ID: B7UHL4.2 Length: 251 Number of Matches: 1

Range 1: 190 to 209 GenPept Graphics ▼Next Match ▲Previous Match

Score	Expect	Method	Identities	Positives	Gaps
23.9 bits(50)	65	Compositional matrix adjust.	13/20(65%)	16/20(80%)	1/20(5%)

```
Query  155  ASELLVEAISLEGIM-NLBA  173
            A++LLVE  SLEGI  NL+A
Sbjct  190  ATQLLVEFKSLEGIYENLNA  209
```

Related Information
AlphaFold Structure - 3D structure displays

Résultat de BLAST – Calcul du pourcentage de couverture

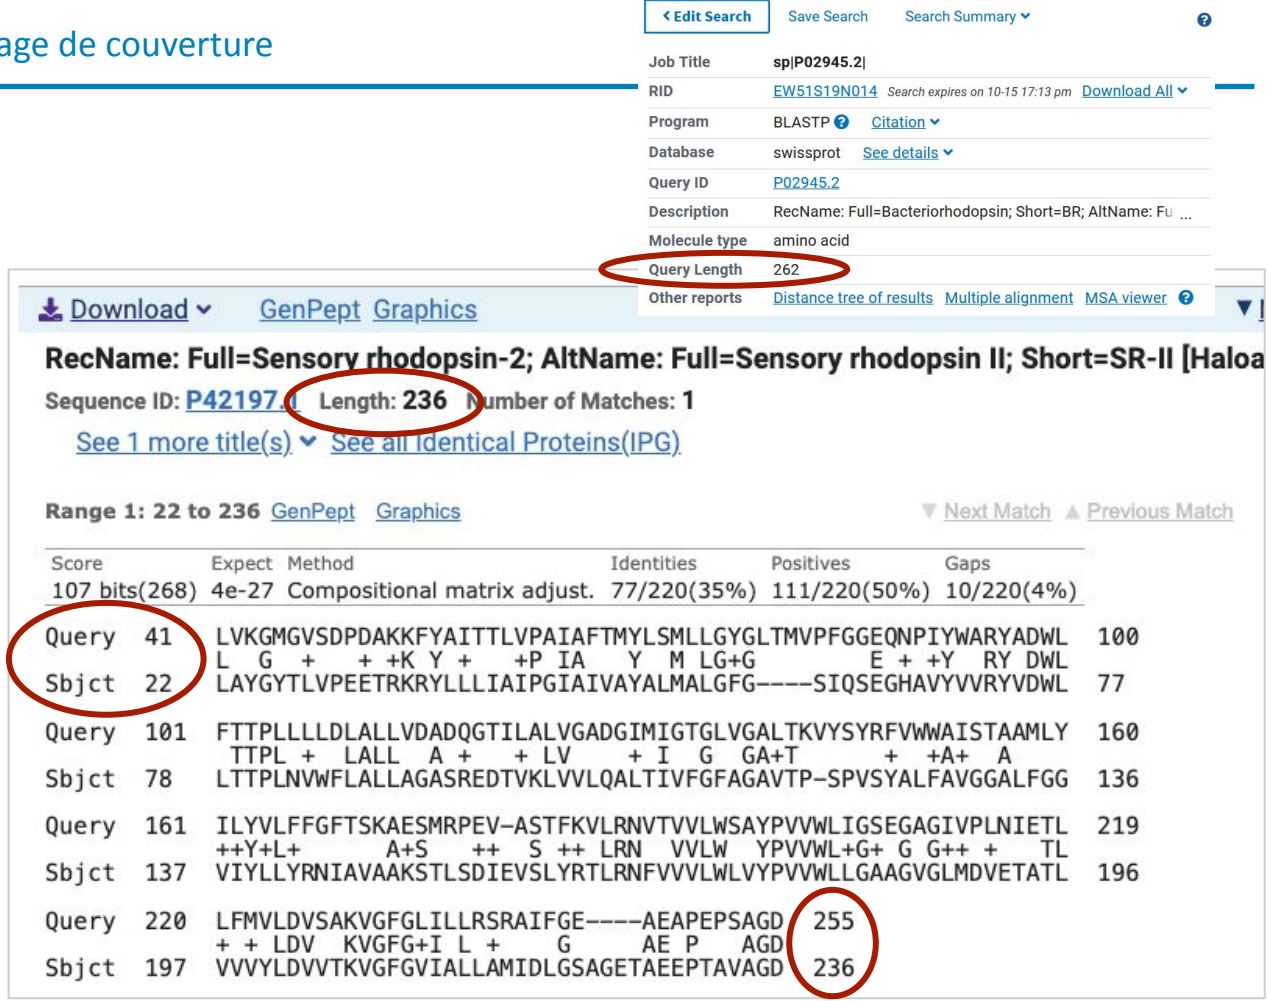
Le **pourcentage de couverture** d'un résultat de BLAST correspond à la **proportion de la séquence requête incluse dans l'alignement**.

Calcul: nombre de résidus de la séquence requête présents dans l'alignement, divisé par la longueur totale de la séquence requête (262). Dans cet exemple:

(255-40) /262 = 0.82 = 82%

Il est également possible de calculer le **pourcentage de couverture de la séquence cible** (celle issue de la base de données) :

(236-21) /236 = 0.91 = 91%



Interprétation d’un alignement BLAST

Vous pouvez consulter une vidéo sur AMUpod concernant l'interprétation d'un alignement BLAST.

Scores et e-valeur retournés par le logiciel BLAST

- Positions de l’alignement
- % d'identité
- % de similarité / de positifs = identités + substitutions conservatives
- % gap
- % couverture
- E-value (= E-valeur = expect)

Tutoriel et exercices

Première partie : collecte d'un jeu de séquences protéiques par similarité de séquence (outil BLAST du NCBI)

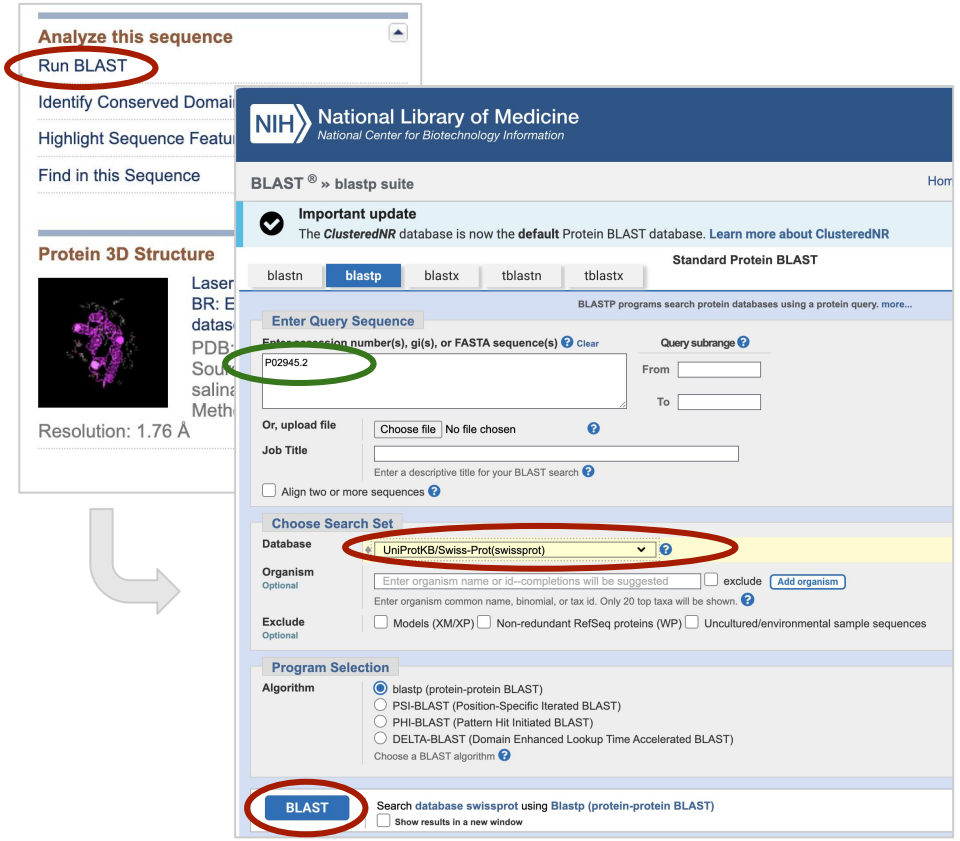
Exercice 1. Alignements par paires et multiples au NCBI

Nous allons maintenant utiliser BLAST pour collecter des séquences homologues à la bactériorhodopsine de l'archée *Halobacterium salinarum*.

Dans un premier temps, nous utiliserons BLASTp via l'interface web du NCBI pour collecter un jeu de séquences homologues à cette protéine (exercice 1), que nous utiliserons ensuite pour produire un alignement multiple (exercice 2).

- Dans la base de données **protein du NCBI**, ouvrez la fiche de la protéine portant l'identifiant **P02945**.
- Dans la section "**Analyze this sequence**" (colonne de droite) cliquez sur "**Run BLAST**". Une fenêtre BLASTP s'ouvre, pré-remplie avec l'identifiant de la protéine dans la boîte de requête ("Query Sequence").
- Dans un premier temps, choisissez comme database **UniProtKB/Swiss-Prot**, qui ne contient que des séquences vérifiées par des humains et est plus petite et donc plus rapide.
- Lancez la recherche en cliquant sur le bouton **BLAST** en bas de page.

Au bout de quelques secondes, le résultat devrait s'afficher.



BLAST – Observer, comprendre le tableau de résultats

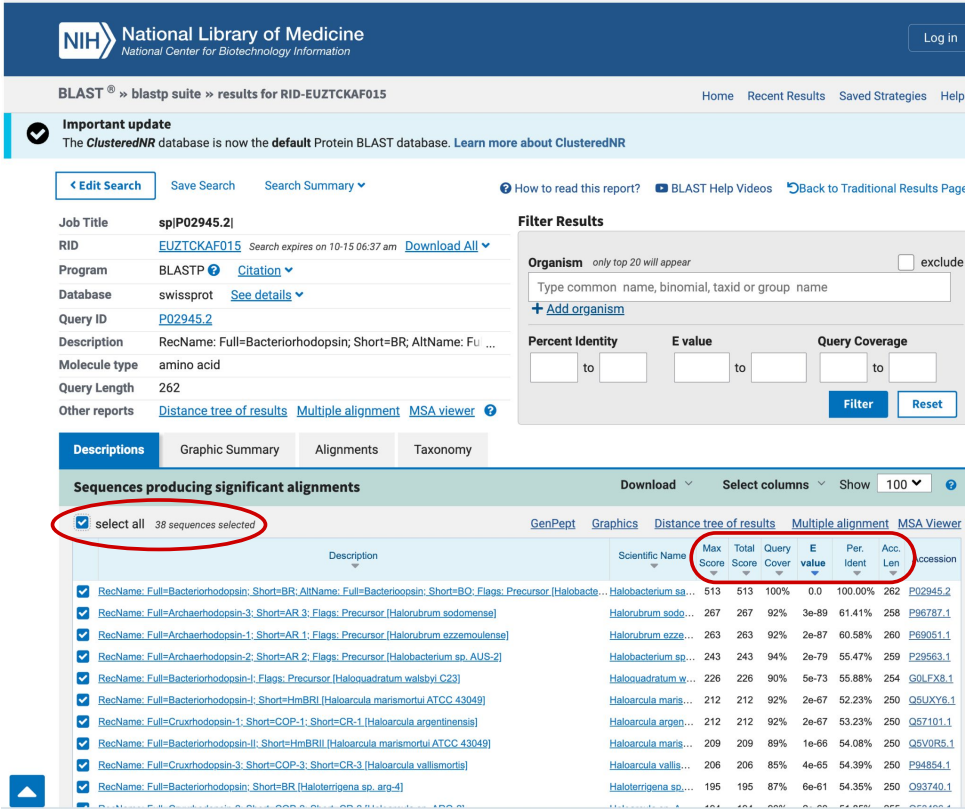
Explorez le tableau (onglet **Descriptions**) pour vous familiariser avec les résultats. Cliquez “Select all”.

- Combien de séquences retourne BLAST?
- Observez l’étendue des e-valeurs (Expect). Comment interprétez-vous les premiers et les derniers alignements en terme de significativité statistique ?
- Quels sont les % d’identité et de couverture (Query Cover) ?

Ces statistiques sont importantes car elles sont nécessaires à la bonne appréciation de la qualité de l’alignement, notamment la significativité de la similarité.

Indices d’interprétation

- *Une significativité élevée (indiquée par une E-valeur très petite) permet de conclure à l’homologie des séquences : émettre l’hypothèse que ces séquences sont issues d’un ancêtre commun.*
- *Un taux de couverture élevé indique que cet alignement concerne la protéine requête dans son ensemble plutôt qu’un sous-domaine particulier.*



BLAST – Observer, comprendre le tableau de résultats

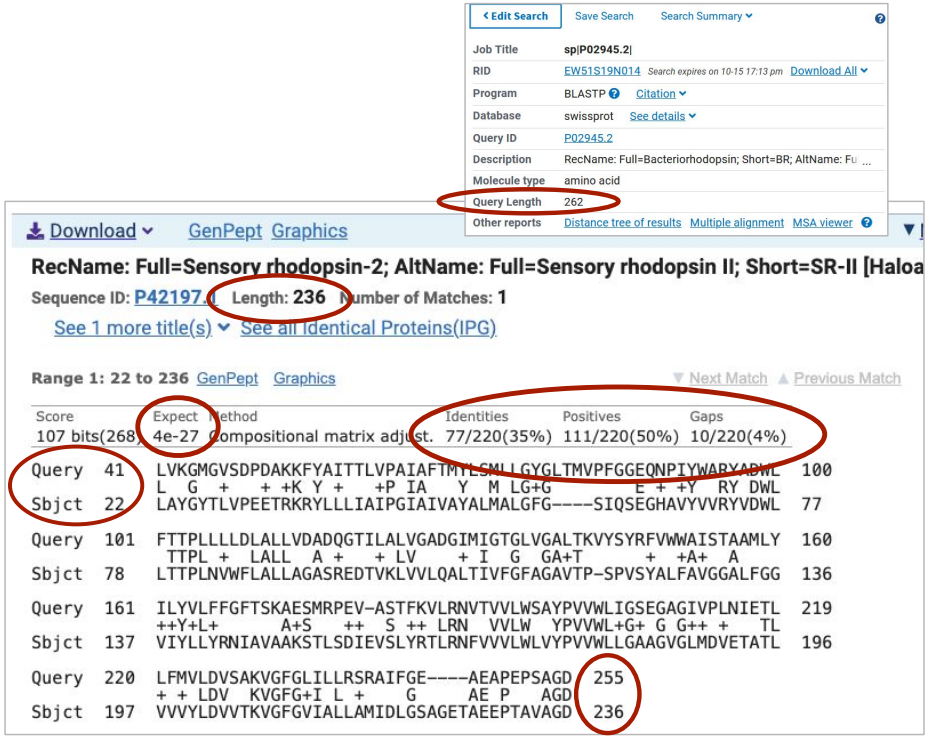
Sur **Ametice**, répondez aux questions du **Questionnaire 1a** “**Alignement local par paire avec BLAST**”.

- Par défaut, les alignements dans le rapport BLAST sont-ils classés en fonction de :
  - E-value croissante
  - E-value décroissante
  - Le pourcentage d’identité croissant
  - Le pourcentage de couverture croissant
- Comment interprétez-vous le premier alignement en termes de significativité statistique ?
  - Cet alignement est hautement significatif (E-value = 0.0) : il est impossible d’obtenir par hasard un alignement de cette qualité.
  - Cet alignement est hautement significatif (E-value = 0.0) : il est extrêmement improbable d’obtenir par hasard un alignement de cette qualité.
  - Une E-value de 0.0 indique que l’alignement n’est pas significatif.
  - Une E-value affichée comme 0.0 signifie que la valeur est si faible que BLAST ne peut pas l’afficher avec précision.
- Comment interprétez-vous le dernier alignement en termes de significativité statistique ?
  - L’E-value obtenue indique que l’alignement n’est pas significatif.
  - L’E-value obtenue suggère que l’alignement est faiblement significatif.
  - L’E-value obtenue montre que l’alignement est hautement significatif.
- Quel est l’intervalle approximatif des pourcentages d’identité parmi les alignements ?
  - Entre 100 % et 25 %
  - Entre 100 % et 50 %
  - Entre 100 % et 80 %
  - Entre 100 % et 90 %
- Quel est l’intervalle approximative des pourcentages de couverture (Query Cover) ?
  - Entre 100 % et 25 %
  - Entre 100 % et 50 %
  - Entre 100 % et 80 %
  - Entre 100 % et 90 %

BLAST – Interprétation d'un alignement

Pour plus de détails, vous pouvez cliquer sur l'onglet "**Alignments**", qui affiche un à un chacun les alignements entre votre protéine de requête et chacune des protéines similaires trouvées dans UniprotKB/Swiss-Prot.

- Observez les positions de début/fin de la séquence requête et de la protéine similaire ("**Subject**") dans les alignements.
- Évaluez les nombres et pourcentages d'identités, de positifs et de gaps.
- Retrouvez les correspondances entre ces chiffres donnés et les caractères de l'alignement.
- Évaluez également la significativité de l'alignement, sur base de la E-valeur ("Expect").



BLAST – Interprétation d'un alignement

- Revenez à l'onglet **Description**, et utilisez la fonction de recherche (**Ctrl + F**) pour trouver la ligne correspondant à l'alignement entre la séquence requête **P02945** et la séquence **P33742**.
- Sur cette ligne, cliquez sur le lien dans la colonne Description ("*Recname: Full=...*"). Le clic vous redirige vers l'onglet **Alignments**, où l'alignement recherché s'affiche automatiquement.

Sur **Ametice**, répondez aux questions du **Questionnaire 1b** - "**Interprétation de l'alignement entre la séquence requête (P02945) et la séquence P33742**".

- Alignement local — Choisissez les phrases correctes
  - C'est un alignement local, car il contient des gaps.
  - C'est un alignement local, car l'alignement commence seulement aux positions 2 et 17 des séquences requête et sujette ; les débuts des deux séquences ne sont pas inclus dans l'alignement.
  - C'est un alignement local, car il se termine aux positions 60 et 72 des séquences requête et sujet ; la fin des deux séquences n'est donc pas incluse dans l'alignement.
  - C'est un alignement local, car il ne commence pas à la même position dans les deux séquences (2 vs 17).
- Statistiques de l'alignement — Choisissez les phrases correctes
  - Le pourcentage d'identité est de 32 %. Cela correspond au nombre de positions où les résidus des deux séquences sont identiques (78), divisé par la longueur de l'alignement (245).
  - Le pourcentage de similarité est de 49 %. Cela correspond au nombre de positions où les résidus ne sont pas identiques mais présentent un score positif (122), divisé par la longueur de l'alignement (245).
  - Le pourcentage de gaps est de 5 %. Cela correspond au nombre de positions contenant des gaps (14), divisé par la longueur de l'alignement (245).
  - La longueur de l'alignement est de 245. Cela correspond au nombre total de positions dans l'alignement, y compris celles contenant des gaps.

BLAST – Interprétation d'un alignement

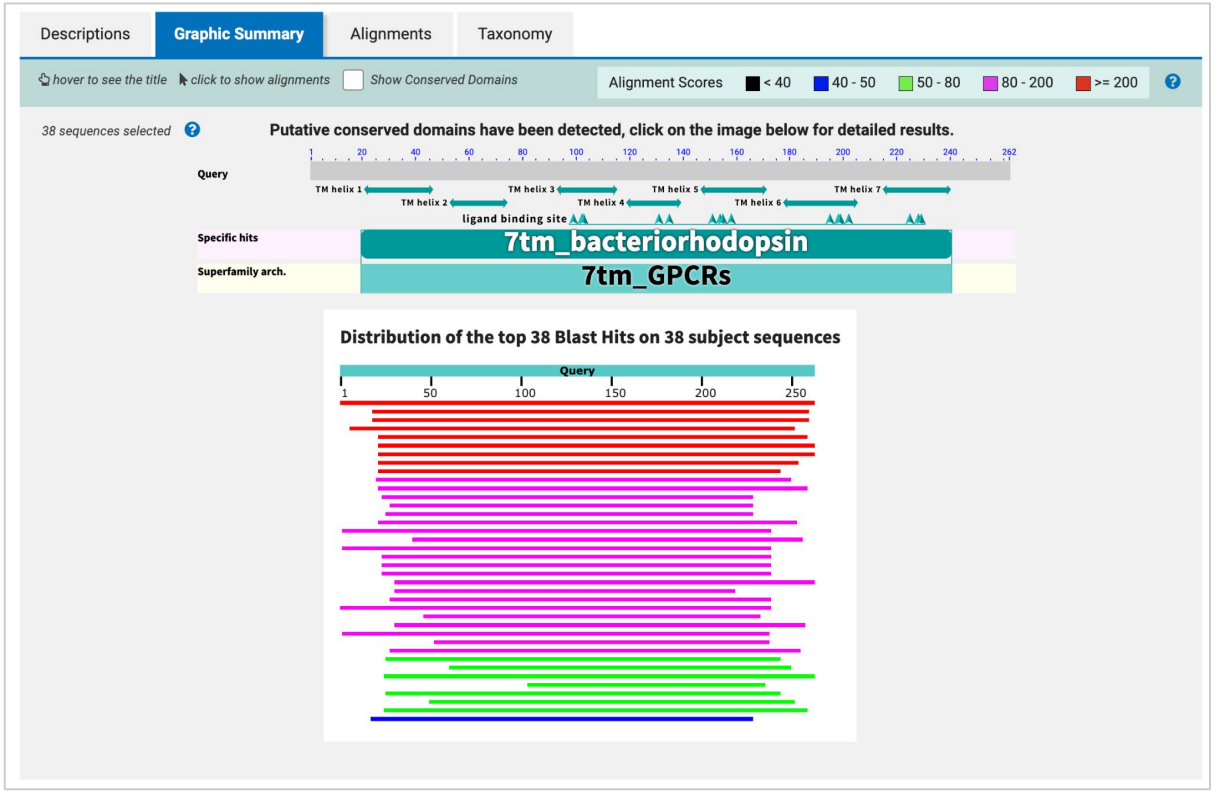
Sur **Ametice**, répondez aux questions du **Questionnaire 1b** - "**Interprétation de l'alignement entre la séquence requête (P02945) et la séquence P33742**". (suite)

- Positions dans l'alignement — Choisissez les phrases correctes
  - Le 3e acide aminé de la séquence requête se trouve à la 2e position de l'alignement.
  - Les signes "+" entre les deux séquences indiquent que les acides aminés à ces positions sont similaires (leurs scores sont positifs).
  - À la 3e position de l'alignement, les acides aminés des deux séquences ont un score nul ou négatif.
  - L'alignement contient cinq indels, de longueur de 1, 4, 6, 1, et 2.
- Significativité de l'alignement — Choisissez les phrases correctes
  - La valeur E (E-value) indique que l'alignement est hautement significatif.
  - La valeur E montre que cet alignement est probablement dû au hasard.
  - Une valeur E très petite indique qu'il est très peu probable d'obtenir un alignement d'aussi bonne qualité par simple hasard.
  - Une E-value très petite signifie que l'alignement n'est pas significatif.

BLAST – Graphic summary

Cliquez maintenant sur l'onglet "**Graphic Summary**" pour retrouver ces informations sous une représentation plus visuelle.

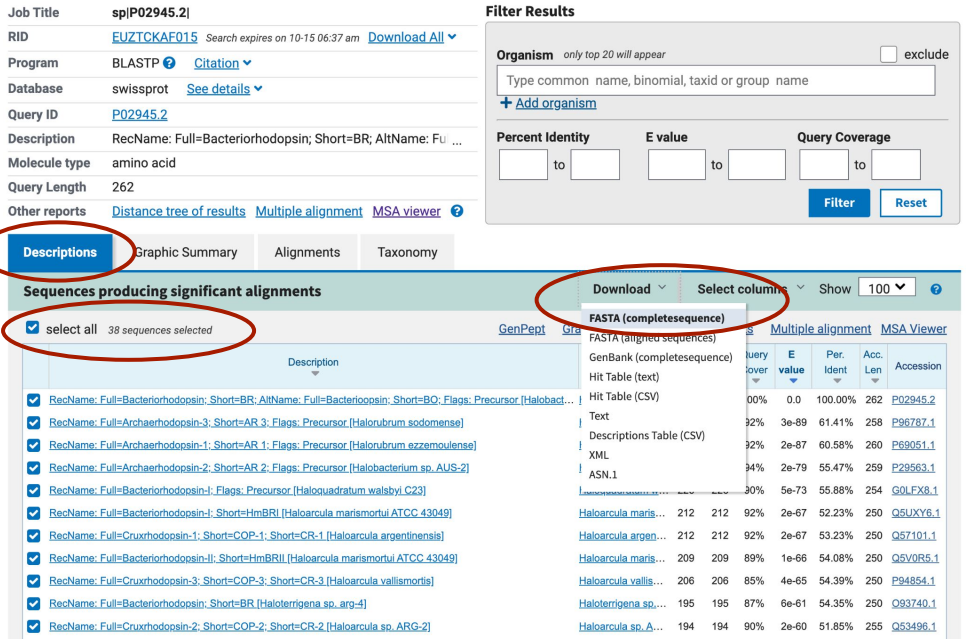
- Chaque barre horizontale colorée correspond à un alignement local (un "hit").
- **Note:** dans ce cas-ci, le **hit au sommet** de la pile correspond à notre **protéine requête**, qui se trouve dans la base de données Swiss-prot. Il couvre donc forcément l'ensemble de la protéine requête.
- L'**étendue de chaque barre** indique la couverture de la protéine requête par chacune des séquences cibles (celles retournées par BLAST).
- La **couleur** indique le degré de significativité, selon le score en bits (voir la légende en haut du graphique).



Collecte des séquences cibles

Nous allons maintenant télécharger les séquences des protéines cibles, pour pouvoir les analyser dans la deuxième partie de ce TP.

- Revenez à l'onglet **Descriptions** du résultat de BLAST,
- Cochez la case "**select all**" pour sélectionner l'ensemble des séquences cibles.
- Cliquez sur le menu déroulant "**Download**" et sélectionnez le format **FASTA (complete sequence)**.
- Sauvegardez ce fichier sur votre ordinateur afin de pouvoir l'utiliser dans l'exercice 2.



Sur Ametice, répondez au questionnaire 1c - Sélection des séquences homologues.

- Lequel des éléments suivants décrit correctement le format FASTA ?
  - C'est un format qui contient uniquement les annotations d'une séquence, sans la séquence elle-même.
  - C'est un format texte contenant une ou plusieurs séquences, chacune précédée d'une ligne de description commençant par le symbole ">".
  - C'est un format binaire utilisé pour stocker des structures protéiques.
  - C'est un format réservé uniquement aux séquences d'ADN.

Collecte des séquences cibles

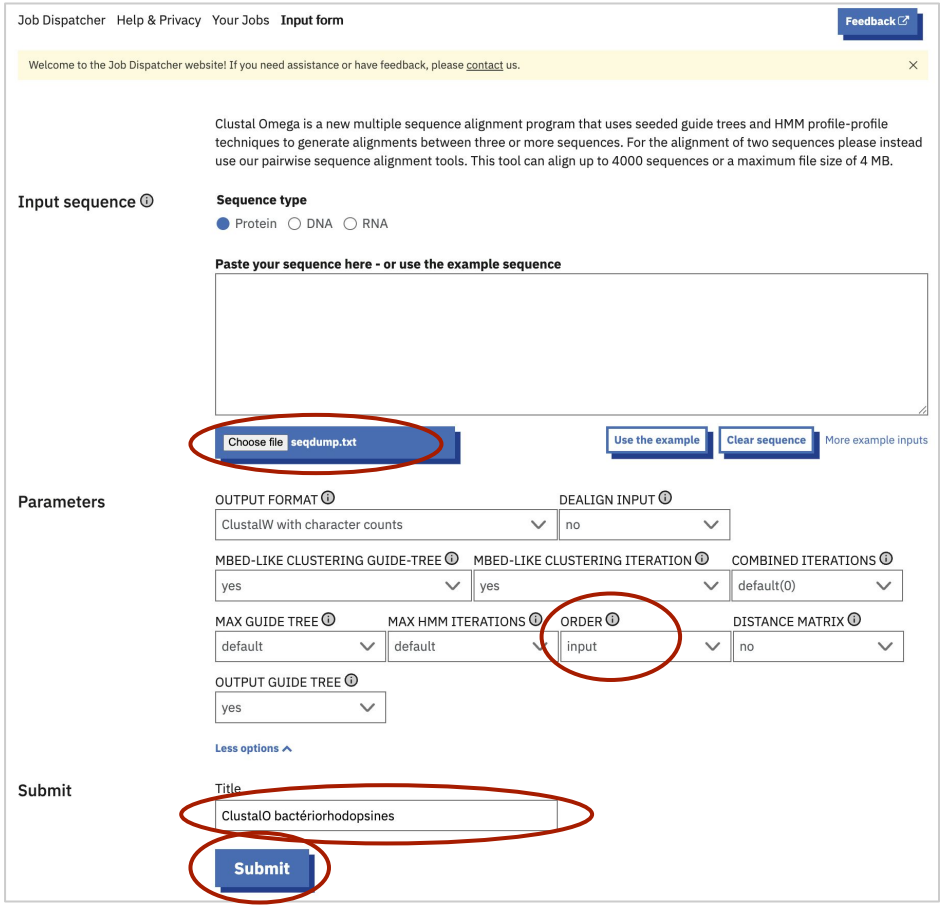
Sur Ametice, répondez au questionnaire 1c. - Sélection des séquences homologues. (suite)

- La première ligne d'une séquence au format FASTA commence toujours par :
  - A. Le nom du gène
  - B. Le caractère >
  - C. Le caractère #
  - D. Le code du taxon
- Analyse des séquences téléchargées. Choisissez les phrases correctes parmi les propositions suivantes :
  - Toutes les séquences téléchargées sont vraisemblablement homologues à la séquence requête.
  - Parmi les séquences téléchargées, l'une est particulièrement courte (131 acides aminés) et elle ne s'aligne pas intégralement avec la séquence requête.
  - La longueur des séquences téléchargées varie entre 131 et 307 acides aminés.
  - Il y a 38 séquences téléchargées.

Deuxième partie : alignements multiples à l'EBI (European Bioinformatics Institute)

Exercice 2. Alignement multiple à l'EBI

- Allez sur la page **MSA** de l'EBI.
- Cliquez sur "**Launch Clustal Omega**".
- Assurez-vous que "**protein**" est sélectionné dans le champ "**Sequence type**".
- Cliquez sur **"Choose File**" et téléversez le fichier fasta obtenu dans l'exercice 1.
- Dans "**Parameters**", cliquez sur "**More options**" et dans le menu **Order** sélectionnez "**Input**". Cette option permet de conserver dans l'alignement l'ordre initial des séquences du fichier FASTA, qui correspondait à la significativité (E-valeur) de BLAST.
- Dans la boîte "**Title**", indiquez le titre de cette analyse, par exemple "**bactériorhodopsines, format ClustalW**". Cette option est utile pour s'y retrouver quand on lance plusieurs analyses en parallèle.
- Cliquez sur **Submit**.
- Observez le résultat.



Exercice 2. Alignement multiple à l'EBI

- Dans la page de résultat, cliquez sur l'onglet **'Alignments'** : votre alignement multiple sera visible.
- Familiarisez-vous avec l'interface d'exploration de l'alignement multiple: **zoom**, glissement de la **fenêtre d'observation**, **schéma de coloration**.
- Testez différents schémas de coloration, notamment la possibilité de ne montrer que certaines catégories tels que les AA chargés, aromatiques etc.

Sur Ametice, répondez au questionnaire 2a. - Alignement multiple



Exercice 2. Alignement multiple à l'EBI

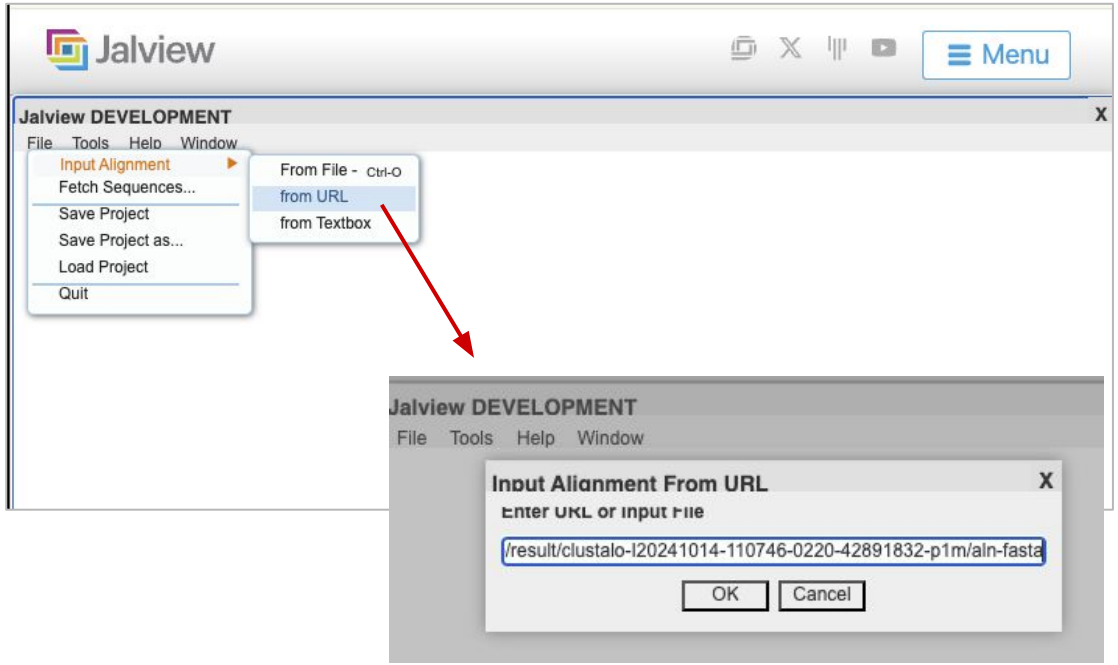
Sur Ametice, répondez au questionnaire 2a. - Alignement multiple

- À quelle position de l'alignement se trouve le premier acide aminé de la séquence P02945 ?
- Quelle est la longueur de la séquence la plus longue de l'alignement ? (Regardez l'onglet 'Tool Output')
- Quelle est la longueur totale de l'alignement ? (Regardez l'onglet 'Alignement')

Jalview – Outil de visualisation et d'édition d'un alignement multiple

La page web de MSA ne permet pas de modifier ni de réordonner les séquences dans l'alignement. Nous allons donc utiliser un outil spécialisé pour visualiser et éditer l'alignement: JALVIEW, via son interface web JalviewJS. (pour info, il est également possible d'installer l'application JalView sur son ordinateur).

- Dans l'onglet "**Result viewers**" de ClustalOmega, copiez le lien qui permet de récupérer cet alignement et servira à l'ouvrir dans le programme **Jalview**.
- Ouvrez **JALVIEW**: Une fenêtre "**Jalview development**" dédiée à l'application apparaît devant celle du navigateur. Vous pouvez positionner cette fenêtre en haut à gauche puis la redimensionner vers le bas à droite pour qu'elle occupe bien votre écran.
- Dans cette fenêtre, cliquez sur le menu "**File**", sélectionnez "**Input alignment**" puis l'option "**From URL**".
- Collez le lien de votre alignement ClustalOmega que vous avez trouvé dans l'onglet "**Result viewers**".
- Cliquez sur **OK**.



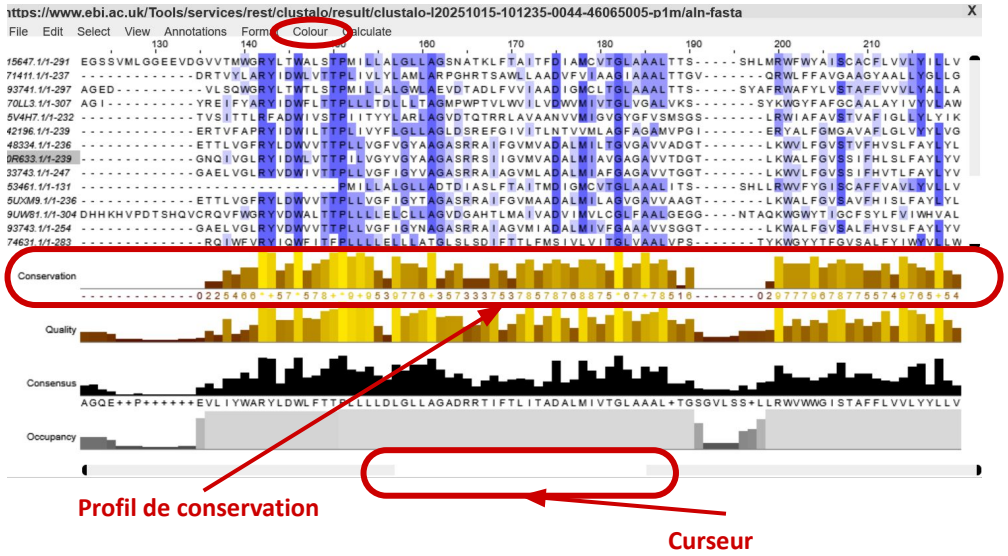
Jalview – Schémas de coloration des résidus

Une nouvelle fenêtre s'ouvre montrant l'alignement multiple.

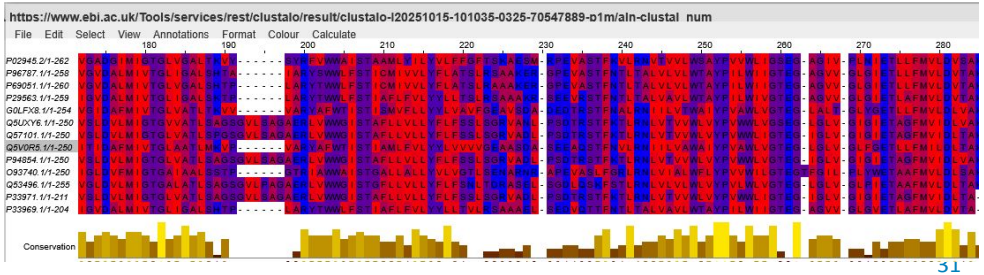
- Déplacez le curseur blanc au bas de la fenêtre pour avancer vers le coeur de l'alignement (dépassez les gaps initiaux, généralement peu informatifs)
- Modifiez l'affichage de l'alignement en changeant la coloration (menu **Colour**) en **Pourcentage d'identité**. Vous devriez observer que les colonnes colorées en bleu plus foncés sont celles qui affichent les valeurs les plus élevées de conservation dans le **profil de conservation** sous l'alignement.
- Essayez ensuite la **coloration Hydrophobicité**.

Conservez cet onglet ouvert, vous reviendrez dessus à une étape ultérieure de ce TP.

Coloration Pourcentage d'identité



Coloration Hydrophobicité : rouge = hydrophobe ; bleu = hydrophile.

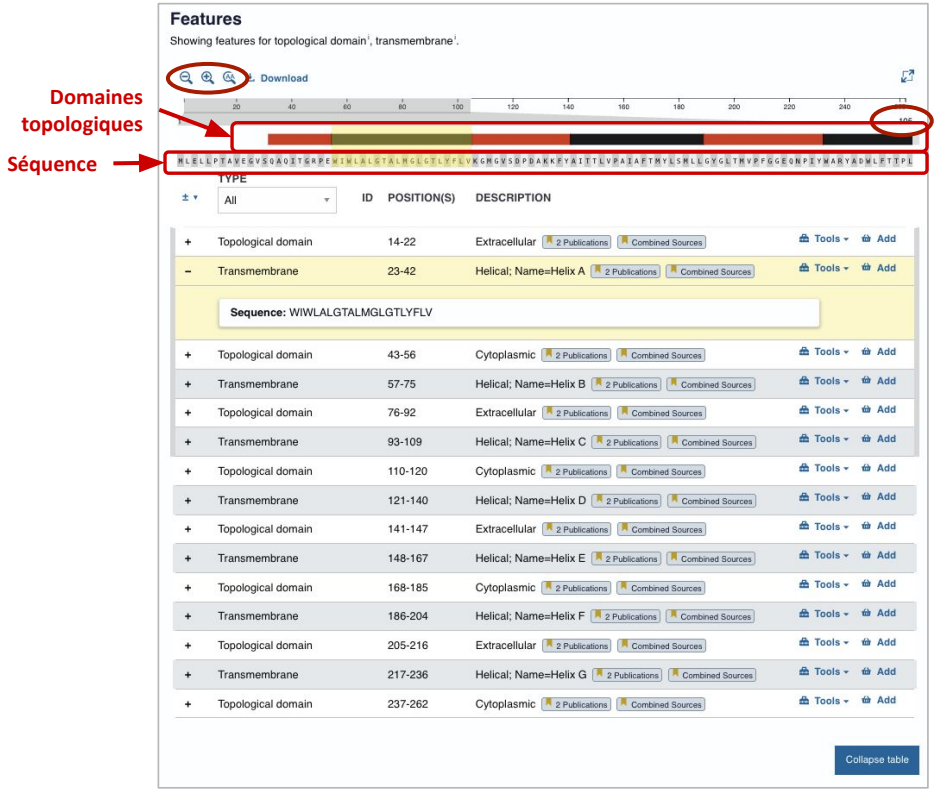


Séquence et structure d'une bactériorhodopsine

Nous allons chercher maintenant des informations sur les propriétés de la **bactériorhodopsine** de l'archée *Halobacterium salinarum.*

- Ouvrez une connexion à Uniprot et cherchez la protéine **P02945**
- Dans la section **Subcellular location**, affichez la table **Features**.
- En haut de la table, **dézoomez** suffisamment pour avoir une vision sur plusieurs domaines topologiques, tout en maintenant la capacité de lire la séquence d'acides aminés.
- En bas de la table, cliquez sur le bouton Expand table pour afficher les coordonnées et la nature de chaque domaine topologique.
- Cliquez sur le **symbole +** à côté de premier domaine topologique de votre choix, pour afficher sa séquence.
- Identifiez les différents types de domaines topologiques :
  - Combien y a-t-il de domaines transmembranaires, cytoplasmiques, et extracellulaires ?
  - Ou sont situées les extrémités N- et C-terminales de la protéine par rapport à la membrane ?

Conservez cet onglet ouvert, vous reviendrez dessus à une étape ultérieure de ce TP.



Jalview – Conservation des domains topologique transmembranaires

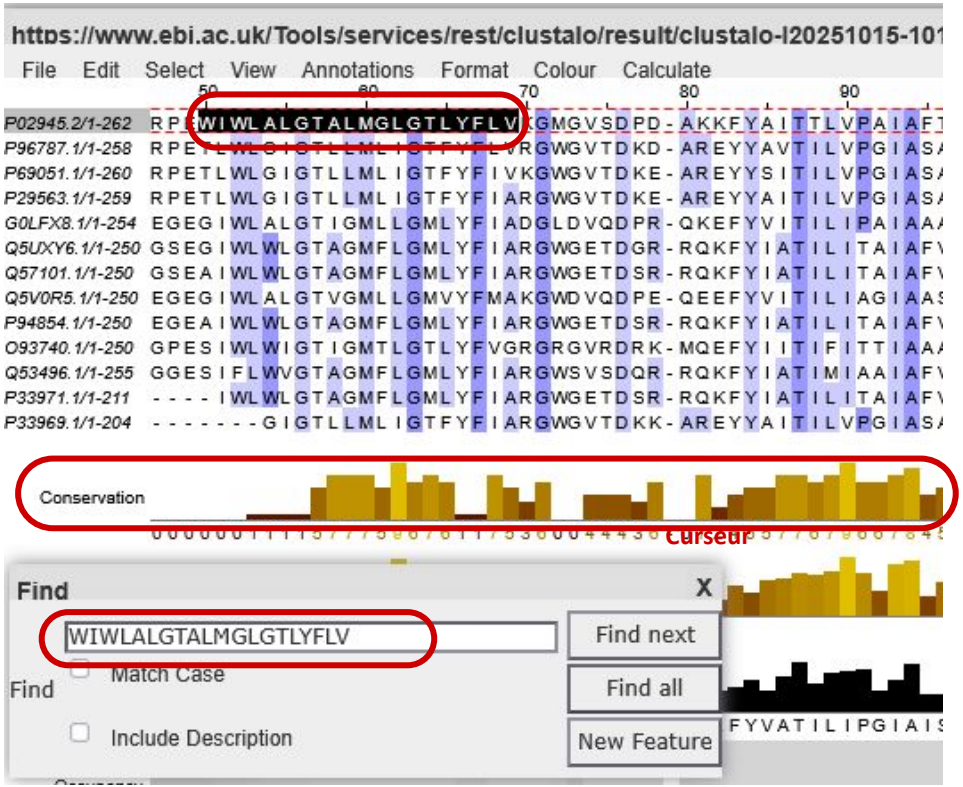
Sur Ametice, répondez au questionnaire 2b. - Domaines topologiques

- Combien de domaines transmembranaires la protéine contient-elle ?
- Combien de domaines cytoplasmiques la protéine contient-elle ?
- Combien de domaines extracellulaires la protéine contient-elle ?
- Où se situe l'extrémité N-terminale de la protéine par rapport à la membrane ?
  - Dans le milieu extracellulaire
  - Dans la membrane
  - Dans le cytoplasme
- Où se situe l'extrémité C-terminale de la protéine par rapport à la membrane ?
  - Dans la membrane
  - Dans le milieu extracellulaire
  - Dans le cytoplasme

Jalview – Conservation des domains topologique transmembranaires

Nous allons maintenant identifier, dans l'alignement, la position de plusieurs régions transmembranaires.

- Dans la fiche **UniProt**, dans le t**ableau des domaines topologiques**, identifiez la **séquence du premier domaine transmembranaire** et copiez-la.
- Dans **Jalview** :
  - Sélectionnez la séquence **P02945** dans l'alignement.
  - Recherchez la séquence correspondant au premier domaine transmembranaire à l'aide de la fonction **Ctrl + F**.
- **Observez le niveau de conservation** de cette région entre les différentes protéines alignées, en le comparant aux régions voisines.
- Répétez cette opération pour quelques autres régions transmembranaires afin de comparer leur degré de conservation.



Jalview – Conservation des domains topologique transmembranaires

Sur Ametice, répondez au questionnaire 2c. - Conservation des domaines topologiques transmembranaires

- Les domaines transmembranaires correspondent à des régions hydrophiles qui traversent la membrane cellulaire.
- Les domaines transmembranaires sont en général constitués d'hélices alpha.
- Les domaines transmembranaires sont en général moins conservés que les régions extracellulaires.
- Dans les hélices alpha transmembranaires, de nombreuses mutations sont éliminées par la sélection naturelle afin de préserver la structure de la protéine.
- À propos de la séquence P02945 dans l'alignement multiple, choisissez les affirmations correctes :
  - Le premier segment transmembranaire (hélice alpha) se situe entre les positions 23 et 42 dans la séquence P02945.
  - Cette même région correspond aux positions 50 à 69 dans l'alignement multiple.
  - Le décalage entre les positions dans la séquence (23 - 42) et dans l'alignement (50 - 69) est dû partiellement à la présence de gaps dans la séquence P02945 en aval de cette région.

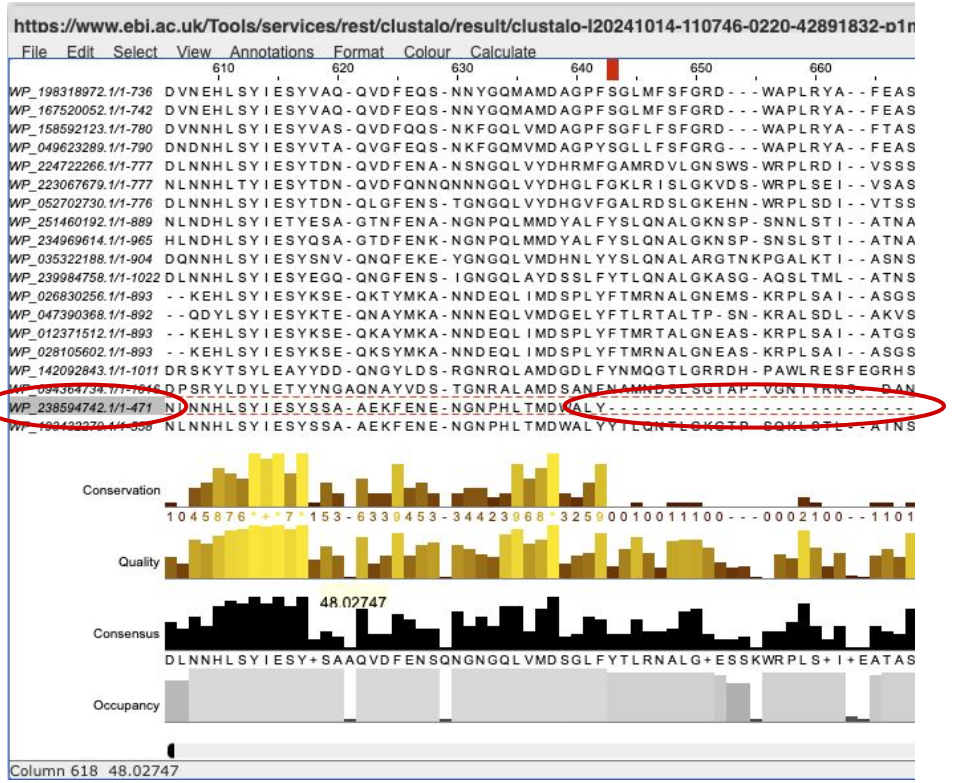
JalView - Edition du fichier d'alignement multiple

Une des premières étapes lorsque l'on édite un alignement multiple est de rechercher d'éventuelles séquences fragmentaires et de les effacer/enlever. Dans notre cas, la séquence Q53461 est beaucoup plus courte que les autres. Il convient donc de la retirer.

- Sélectionnez la séquence Q53461 en cliquant sur son identifiant.
- Utilisez le raccourci **Ctrl+X** pour la supprimer.

Astuce: *au cas où vous devriez supprimer plusieurs séquences d'un alignement, JalView permet également de sélectionner :*

- *plusieurs séquences en cliquant successivement leurs identifiants tout en maintenant la touche Ctrl enfoncée*
- *un bloc de séquences en cliquant sur la première, puis en maintenant la touche Shift avant de cliquer sur la dernière.*

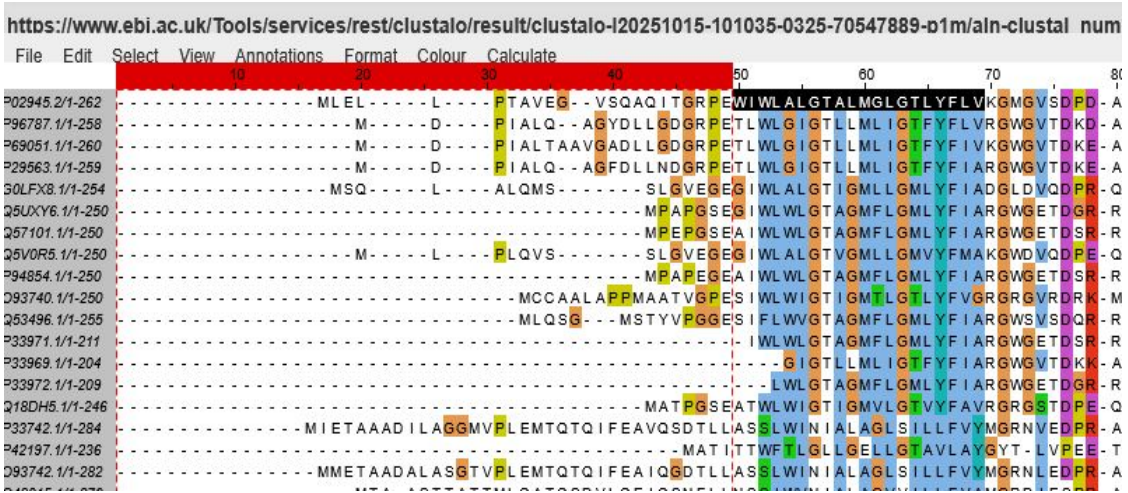


Suppression des séquences terminales variables

Une fois les protéines fragmentaires éliminées, on observe souvent dans les alignements que les portions N- et C-terminales sont moins conservées (plus variables). Les indels en régions terminales ont peu d'impact fonctionnel en général, car ils ne modifient pas le cœur de la protéine. Nous allons borner l'alignement en ne gardant que la portion située entre (et incluant) les premières et dernières régions transmembranaires.

Nous avons vu que la première position de la première hélice alpha correspond à la position 50 dans l'alignement. **Nous allons donc supprimer les 49 premières positions de l'alignement.**

- **Sélectionnez les colonnes à supprimer** en cliquant au-dessus de la première position de l'alignement puis en étirant la sélection jusqu'à la position souhaitée (c'est à dire jusqu'à la position 49).
- Utilisez le raccourci **Ctrl+X** pour supprimer la région sélectionnée.

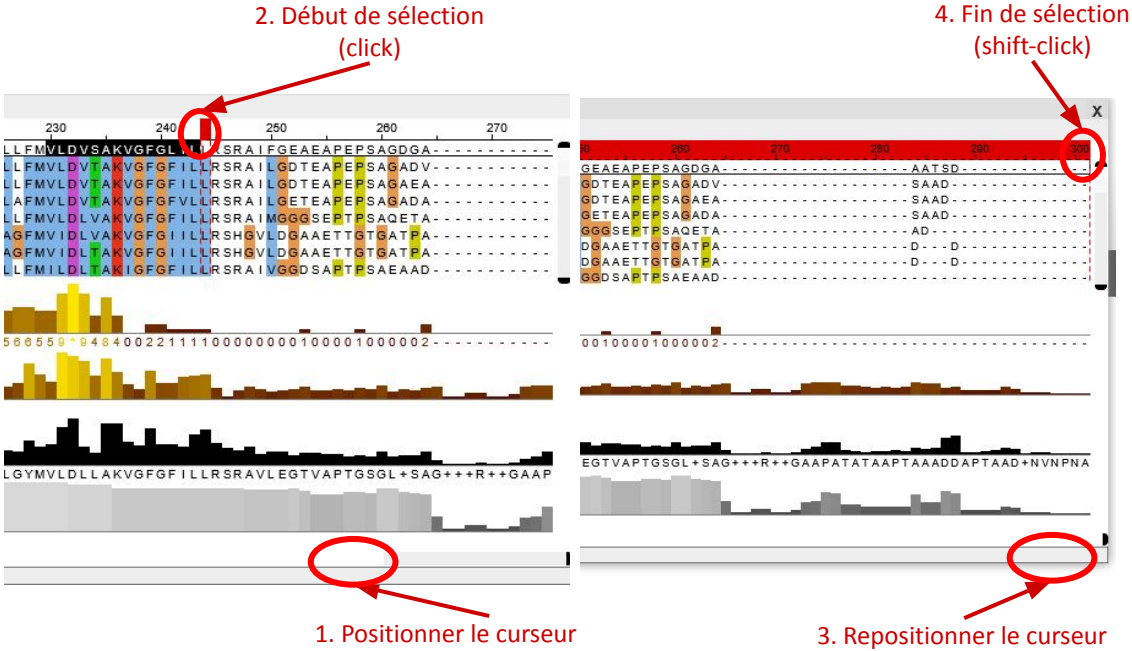


Suppression des séquences terminales excédentaires

Faites de même pour **supprimer la région C-terminale** après la dernière hélice alpha.

Astuce: *vous pouvez sélectionner un nombre de colonnes qui dépasse la taille de votre fenêtre en cliquant sur les en-têtes de colonnes tout en maintenant la touche Shift-Click enfoncée*

- **Positionnez le curseur** (rectangle blanc en bas de la fenêtre) sur la première colonne après la dernière hélice alpha.
- **Cliquez sur l'en-tête de la première colonne à sélectionner** (celle qui suit immédiatement la séquence référence)
- **Déplacez le curseur** jusqu'à la dernière colonne à supprimer (dans votre cas, la dernière de l'alignement)
- **Shift-click sur l'en-tête de cette colonne**.
- **Ctrl-X** pour supprimer toutes les colonnes sélectionnées



Jalview – Conservation des domains topologique transmembranaires

Sur Ametice, répondez au questionnaire 2d. - Longueur de l'alignement édité

- Quelle est la longueur de l'alignement raccourci ?
- Quelle est la longueur de la séquence P02945 entre (et incluant) la première et la dernière région transmembranaire ?
- Combien de positions de l'alignement raccourci contiennent un gap dans la séquence P02945 (c'est-à-dire le nombre total de caractères "–" dans la séquence) ?